

姓名：徐诗霖
学号：202622080929

1. 什么是机器学习？

机器学习是人工智能的一个重要分支，它研究如何让计算机系统通过数据和经验自动改进自身的性能，而不是完全依赖人工编写的固定规则。

我认为比较清楚的定义是 Tom Mitchell 给出的定义：

对于某类任务 T 和性能度量 P ，如果一个计算机程序在经验 E 的帮助下，在任务 T 上的性能 P 得到提高，那么就称该程序从经验 E 中学习。

用更直观的话说，机器学习就是让模型从已有数据中发现规律，并利用这些规律对新的未知数据进行判断、分类、预测或决策。例如，根据历史房价数据预测新房子的价格，根据邮件内容判断是否为垃圾邮件，根据医学影像辅助识别疾病等。

2. 机器学习的基础分类及其定义

机器学习通常可以分为以下几类：

2.1 监督学习

监督学习是指训练数据中既包含输入样本，也包含对应的正确输出标签。模型通过学习输入和输出之间的映射关系，对新的输入进行预测。

常见任务包括：

- 分类：输出是离散类别，例如判断邮件是否为垃圾邮件。
- 回归：输出是连续数值，例如预测房价、温度或销售额。

2.2 无监督学习

无监督学习是指训练数据中只有输入样本，没有人工给定的标签。模型需要自己发现数据中的结构、分布或隐藏规律。

常见任务包括：

- 聚类：把相似样本分到同一组，例如客户分群。
- 降维：用更少的特征表示原始数据，例如主成分分析。
- 异常检测：发现与大多数样本明显不同的数据点。

2.3 半监督学习

半监督学习是指训练数据中只有一部分样本带有标签，另一部分样本没有标签。它同时利用少量有标签数据和大量无标签数据共同训练模型。

这种方法适用于标注成本较高、但未标注数据容易获得的场景，例如医学图像识别、文本分类等。

2.4 强化学习

强化学习是指智能体通过与环境交互获得的相关反馈来学习相关策略。智能体执行动作后会得到奖励或惩罚，并根据反馈不断调整行为，使长期累计奖励最大化。

典型例子包括游戏 AI、机器人控制、自动驾驶路径规划等。

3. 训练集、验证集和测试集的作用

在机器学习任务中，通常会把数据划分为训练集、验证集和测试集，它们的作用不同。

3.1 训练集

训练集用于训练模型参数。模型通过训练集中的样本学习输入和输出之间的关系。例如在线性回归中，模型会利用训练集来估计权重参数。

3.2 验证集

验证集用于模型选择和调参。比如选择不同的模型结构、学习率、正则化系数（提高模型的泛化能力用于处理非线性的复杂情况）、树的深度等超参数时，可以通过验证集上的表现进行比较。

验证集不直接用于模型的参数更新，而是帮助判断哪一种选择更合适。

3.3 测试集

测试集用于最终评估模型在未知数据上的泛化能力。测试集应该只在模型训练和调参完成后使用，避免模型间接“看到”测试数据，导致评估结果过于乐观。

简而言之：

- 训练集：用于学习参数。
- 验证集：用于选择模型和调整超参数。
- 测试集：用于最终客观评估模型性能。

4. 什么是过学习？有哪些避免过学习的方法？

过学习通常也称为过拟合，是指模型在训练集上表现很好，但在新的未知数据上表现较差。也就是说，模型不只学习到了数据中的一般规律，还把训练数据中的噪声、偶然性和细节也记住了。

例如，一个模型在训练集上的准确率达到 99%，但在测试集上只有 70%，就可能存在过拟合问题。

避免过拟合的常见方法包括：

1. 增加训练数据

更多、更有代表性的数据可以帮助模型学习更稳定的规律。

2. 降低模型复杂度

例如减少神经网络层数或参数数量，限制决策树深度，减少特征数量等。

3. 使用正则化

通过在损失函数中加入惩罚项限制参数过大。常见方法有 L1 正则化和 L2 正则化。

4. 交叉验证

把数据多次划分为训练集和验证集，综合评估模型表现，减少偶然划分带来的影响。

5. 早停法

在训练过程中观察验证集误差，当验证集误差开始上升时停止训练。

6. 数据增强

对已有样本进行合理变换，例如图像旋转、裁剪、翻转等，使模型看到更多变化。

7. Dropout

在神经网络训练过程中随机丢弃部分神经元，减少模型对局部特征的过度依赖。

5. 极大似然估计和最大后验参数估计的区别和联系

5.1 极大似然估计

极大似然估计，即 MLE，Maximum Likelihood Estimation，是在给定观测数据的情况下，寻找使这些数据出现概率最大的参数。

设参数为 (θ) ，数据为 (D) ，极大似然估计为：

$$\theta_{MLE} = \arg \max_{\theta} P(D|\theta)$$

它只考虑数据在不同参数下出现的可能性，不显式加入参数本身的先验知识。

5.2 最大后验参数估计

最大后验估计，即 MAP，Maximum A Posteriori Estimation，是在给定观测数据后，寻找后验概率最大的参数。

根据贝叶斯公式：

$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{P(D)}$$

由于 $P(D)$ 与 (θ) 无关，所以：

$$\theta_{MAP} = \arg \max_{\theta} P(D|\theta)P(\theta)$$

MAP 不仅考虑数据的似然 ($P(D|\theta)$), 还考虑参数的先验分布 ($P(\theta)$)。

5.3 区别

- MLE 只利用观测数据, 不考虑参数的先验分布。
- MAP 同时利用观测数据和先验知识。
- 当数据量较少时, MAP 往往能通过先验减少估计的不稳定性。
- 当数据量很大时, 先验的影响通常会变弱, MAP 和 MLE 的结果可能趋于接近。

5.4 联系

如果参数的先验分布 ($P(\theta)$) 是均匀分布, 那么 MAP 等价于 MLE。也可以把 MLE 看成 MAP 在无信息先验或均匀先验情况下的特殊形式。

6. 癌症检测阳性后的患病概率

题目条件:

- 患癌概率: ($P(C)=1\%=0.01$)
- 未患癌概率: ($P(\neg C)=0.99$)
- 患癌者检测为阳性的概率: ($P(+|C)=90\%=0.9$)
- 未患癌者检测为阴性的概率: ($P(-|\neg C)=90\%=0.9$)
- 因此未患癌者检测为阳性的概率: ($P(+|\neg C)=1-0.9=0.1$)

要求的是检测阳性后真正患癌的概率, 即 ($P(C|+)$)。

根据贝叶斯公式:

$$P(C|+) = \frac{P(+|C)P(C)}{P(+|C)P(C) + P(+|\neg C)P(\neg C)}$$

代入数值:

$$P(C|+) = \frac{0.9 \times 0.01}{0.9 \times 0.01 + 0.1 \times 0.99}$$

$$P(C|+) = \frac{0.009}{0.009 + 0.099}$$

$$P(C|+) = \frac{0.009}{0.108} \approx 0.0833$$

所以, 一个人检测为阳性后, 真正患癌的概率约为:

$$8.33\%$$

这个结果看起来比 90% 小很多，原因是该癌症在人群中的基础患病率只有 1%，假阳性人数会比较多。

7. 什么是共轭先验？它有什么好处？举例说明

共轭先验是贝叶斯统计中的一个概念。对于某个似然函数，如果选择某种先验分布后，得到的后验分布与先验分布属于同一分布族，那么这个先验分布就称为该似然函数的共轭先验。

它的主要好处是：

- 计算方便，可以得到解析形式的后验分布。
- 更新规则简单，适合在线学习或增量学习。
- 便于解释先验信息如何被数据更新。

一个经典例子是伯努利分布参数的共轭先验。

假设一次试验结果 (x) 服从伯努利分布：

$$x \sim \text{Bernoulli}(\theta)$$

其中 (θ) 表示成功概率。伯努利分布参数 (θ) 的共轭先验是 Beta 分布：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

如果观察到 (n) 次试验，其中成功 (k) 次，失败 ($n-k$) 次，则后验分布仍然是 Beta 分布：

$$\theta|D \sim \text{Beta}(\alpha + k, \beta + n - k)$$

因此，Beta 分布是伯努利分布和二项分布参数的共轭先验。

8. 设计一个例子，体现 MLE、MAP 以及贝叶斯学习预测

可以用“估计一枚硬币正面朝上的概率”作为例子。

设硬币正面朝上的概率为 (θ)。我们连续抛硬币 10 次，观察到 7 次正面、3 次反面。

8.1 极大似然估计

在 MLE 中，只根据观测数据估计参数。

由于 10 次中有 7 次正面，所以：

$$\theta_{MLE} = \frac{7}{10} = 0.7$$

这表示根据已有数据，最可能的正面概率是 0.7。

8.2 最大后验估计

在 MAP 中，除了数据，还要考虑先验知识。

假设我们事先认为硬币大致是公平的，因此选择先验分布：

$$\theta \sim \text{Beta}(2, 2)$$

观察到 7 次正面和 3 次反面后，后验分布为：

$$\theta|D \sim \text{Beta}(2 + 7, 2 + 3) = \text{Beta}(9, 5)$$

Beta 分布 ($\text{Beta}(\alpha, \beta)$) 的众数为：

$$\frac{\alpha - 1}{\alpha + \beta - 2}$$

因此：

$$\theta_{MAP} = \frac{9 - 1}{9 + 5 - 2} = \frac{8}{12} \approx 0.667$$

可以看到，MAP 的结果比 MLE 的 0.7 更接近 0.5，因为先验中包含了“硬币可能较公平”的信息。

8.3 贝叶斯学习预测

贝叶斯学习预测不是只给出一个固定参数，而是考虑整个后验分布来预测下一次结果。

下一次抛硬币为正面的预测概率为后验均值：

$$P(x_{new} = 1|D) = \frac{\alpha'}{\alpha' + \beta'}$$

其中 ($\alpha'=9, \beta'=5$)，所以：

$$P(x_{new} = 1|D) = \frac{9}{9 + 5} = \frac{9}{14} \approx 0.643$$

因此：

- MLE 得到的参数估计是 (0.7)。
- MAP 得到的参数估计约为 (0.667)。
- 贝叶斯学习预测下一次为正面的概率约为 (0.643)。

这个例子说明：MLE 只看数据，MAP 会结合先验，而贝叶斯学习预测会综合整个后验分布进行预测。