

姓名：徐诗霖
学号：202622080929

第三讲作业

1. 用线性回归处理非线性问题

线性回归中的“线性”通常是指模型对参数是线性的，并不要求输入变量与输出变量之间必须呈直线关系。因此，可以先对原始输入进行非线性特征变换，再对变换后的特征使用线性回归。

下面给出三个具体例子。

例 1：多项式回归

假设某种产品的销量先随广告投入增加而快速上升，之后增长速度逐渐减慢。可以构造二次特征：

$$\phi(x) = [1, x, x^2]^T,$$

得到模型

$$\hat{y} = w_0 + w_1x + w_2x^2.$$

该模型关于 (x) 是一条曲线，但关于参数 (w₀,w₁,w₂) 仍然是线性的，因此可以用最小二乘法估计参数。类似地，还可以加入 (x³,x⁴) 等高次项，但次数过高时需要注意过拟合。

例 2：周期基函数回归

若要预测具有周期性的月度用电量，可把月份或时间 (t) 映射为正弦和余弦特征：

$$\hat{y} = w_0 + w_1 \sin(\omega t) + w_2 \cos(\omega t).$$

其中 (ω) 由周期决定。该模型能够描述季节性变化，同时仍可采用线性回归估计 (w₀,w₁,w₂)。

例 3：分段线性或样条基函数回归

假设温度低于某个阈值 (c) 时耗电量变化较慢，超过阈值后空调使用使耗电量迅速增加。可以加入截断线性基函数：

$$(x - c)_+ = \max(0, x - c),$$

建立模型

$$\hat{y} = w_0 + w_1x + w_2(x - c)_+ + \dots$$

当 $(x \leq c)$ 时，第三项为 0；当 $(x > c)$ 时，模型斜率发生变化。通过设置多个节点并使用样条基函数，可以拟合更平滑、更复杂的非线性关系。

除上述方法外，还可以使用对数、指数、径向基函数等特征变换。关键思想都是先将输入映射到新的特征空间，再使用对参数线性的模型完成回归。

2. 最小二乘法及三个数据点的拟合

2.1 基本定义

最小二乘法通过最小化预测值与真实值之间的平方误差来估计模型参数。

对线性模型

$$\hat{y}_i = \mathbf{w}^T \mathbf{x}_i + b,$$

其平方误差损失函数可以写为

$$J(\mathbf{w}, b) = \sum_{i=1}^n [y_i - (\mathbf{w}^T \mathbf{x}_i + b)]^2.$$

有时也写成

$$J(\mathbf{w}, b) = \frac{1}{2n} \sum_{i=1}^n [y_i - (\mathbf{w}^T \mathbf{x}_i + b)]^2.$$

两种写法只相差正常数，不会改变使损失函数最小的参数。

用矩阵表示时，若截距已经包含在设计矩阵 (X) 中，则

$$J(\boldsymbol{\beta}) = \|\mathbf{y} - X\boldsymbol{\beta}\|_2^2,$$

在 $(X^T X)$ 可逆时，解析解为

$$\hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T \mathbf{y}.$$

2.2 概率观点解释

假设每个样本满足

$$y_i = \mathbf{w}^T \mathbf{x}_i + b + \varepsilon_i,$$

并且噪声相互独立、服从均值为 0、方差为 (σ^2) 的高斯分布：

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

于是

$$p(y_i | \mathbf{x}_i, \mathbf{w}, b) = \mathcal{N}(y_i | \mathbf{w}^T \mathbf{x}_i + b, \sigma^2).$$

全部样本的似然函数为

$$p(D|\mathbf{w}, b) = \prod_{i=1}^n p(y_i|\mathbf{x}_i, \mathbf{w}, b).$$

对似然函数取负对数并去掉与参数无关的常数，可得

$$-\log p(D|\mathbf{w}, b) = \frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - (\mathbf{w}^T \mathbf{x}_i + b)]^2 + C.$$

因此，在独立同方差高斯噪声假设下，最大似然估计等价于最小化平方误差。

2.3 拟合给定的三个数据点

给定数据点

$$(1, 0.9), \quad (0, 0.1), \quad (2, 2),$$

用一元线性模型

$$\hat{y} = wx + b$$

进行拟合。平方误差为

$$J(w, b) = (0.9 - w - b)^2 + (0.1 - b)^2 + (2 - 2w - b)^2.$$

令损失函数分别对 (w) 和 (b) 的偏导数为 0，可以得到正规方程

$$\begin{cases} 3b + 3w = 3, \\ 3b + 5w = 4.9. \end{cases}$$

两式相减可得

$$2w = 1.9,$$

因此

$$w = 0.95, \quad b = 0.05.$$

最终拟合直线为

$$\boxed{\hat{y} = 0.95x + 0.05}.$$

各点的预测结果为：

(x)	真实值 (y)	预测值 (y)	残差
0	0.1	0.05	0.05
1	0.9	1.00	-0.10

(x)	真实值 (y)	预测值 (y)	残差
2	2.0	1.95	0.05

残差平方和为

$$0.05^2 + (-0.10)^2 + 0.05^2 = 0.015.$$

3. 岭回归

3.1 定义与损失函数

岭回归是在普通最小二乘回归的损失函数中加入参数的 (λ) 正则化项。常用形式为

$$J(\mathbf{w}, b) = \sum_{i=1}^n [y_i - (\mathbf{w}^T \mathbf{x}_i + b)]^2 + \|\mathbf{w}\|_2^2,$$

其中

$$\|\mathbf{w}\|_2^2 = \sum_{i=1}^n w_i^2,$$

(λ) 是正则化系数。实际应用中一般不对截距 (b) 进行惩罚。

当特征已经中心化且不单独考虑截距时，岭回归的解析解为

$$\hat{\mathbf{w}}_{\text{ig}} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}.$$

3.2 概率观点解释

首先仍假设观测噪声服从高斯分布：

$$\mathbf{y}|X, \mathbf{w} \sim \mathcal{N}(X\mathbf{w}, \sigma^2).$$

然后为参数设置零均值各向同性高斯先验：

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \lambda^{-1} I).$$

根据贝叶斯公式，

$$p(\mathbf{w}|D) \propto p(D|\mathbf{w})p(\mathbf{w}).$$

对后验概率取负对数并忽略常数，可得

$$-\log p(\mathbf{w}|D) = \frac{1}{2\sigma^2} \|\mathbf{y} - X\mathbf{w}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2 + C.$$

这与岭回归的目标函数等价，其中正则化强度与

$$= \frac{\sigma^2}{2}$$

成比例。因此，岭回归可以解释为在高斯噪声和高斯参数先验下，对参数进行最大后验估计。

3.3 优点

1. **缓解过拟合。** (λ_2) 惩罚会限制参数绝对值，降低模型方差，提高泛化能力。
2. **缓解多重共线性。** 当特征之间高度相关时，普通最小二乘估计可能非常不稳定；加入 (λ) 后可以改善矩阵的条件数。
3. **提高数值稳定性。** 即使 $(X^T X)$ 奇异或接近奇异， $(X^T X + I)$ 通常仍然可逆。
4. **保留全部特征。** 岭回归通常将系数压缩到接近 0，但很少使系数严格等于 0，适合许多特征都可能有一定作用的场景。
5. **实现简单。** 目标函数是凸函数，通常具有唯一的全局最优解。

4. LASSO 回归

4.1 定义与损失函数

LASSO 的全称是 Least Absolute Shrinkage and Selection Operator。它在平方误差损失中加入参数的 (λ_1) 正则化项：

$$J(\mathbf{w}, b) = \sum_{i=1}^n [y_i - (\mathbf{w}^T \mathbf{x}_i + b)]^2 + \|\mathbf{w}\|_1,$$

其中

$$\|\mathbf{w}\|_1 = \sum_{i=1} |w_i|.$$

和岭回归类似，截距 (b) 通常不参与正则化。

4.2 概率观点解释

假设观测噪声仍服从高斯分布，同时假设每个参数相互独立，并服从以 0 为中心的拉普拉斯分布：

$$p(w) = \frac{1}{2} \exp\left(-\frac{|w|}{\lambda_1}\right)$$

由于拉普拉斯先验的负对数与 $(|w|)$ 成正比，所以最大化参数的后验概率等价于最小化

$$\|\mathbf{y} - X\mathbf{w}\|_2^2 + \|\mathbf{w}\|_1.$$

因此，LASSO 可以看作在高斯观测噪声和拉普拉斯参数先验下的最大后验估计。

4.3 特点

1. 产生稀疏解。LASSO 能使部分参数严格等于 0，因此可以自动完成特征选择。
2. 提高模型可解释性。删除作用较弱的特征后，模型通常更加简洁。
3. 缓解过拟合。对参数进行约束可以降低模型复杂度和方差。
4. 目标函数是凸函数但不可处处求导。 $(w=0)$ 处的绝对值函数不可导，常使用坐标下降法、近端梯度法等算法求解。
5. 对高度相关的特征可能不稳定。当多个特征高度相关时，LASSO 可能只保留其中一个，具体保留哪一个可能随样本变化。
6. 需要选择正则化系数。 λ 过小会使正则化作用不足，过大则可能删除有用特征，一般通过交叉验证选择。

岭回归和 LASSO 的主要区别是：岭回归使用 (λ_2) 正则化，倾向于均匀压缩参数；LASSO 使用 (λ_1) 正则化，能够将部分参数压缩为 0。

5. 偏置 方差 预测误差与模型复杂度

图中的横轴是模型复杂度，纵轴是预测误差。随着模型复杂度由低变高，模型通常经历欠拟合、较好拟合和过拟合三个阶段。

5.1 偏置与复杂度

偏置表示模型的平均预测与真实规律之间的系统性差异。

- 模型复杂度低时，模型表达能力不足，难以描述数据中的真实关系，因此偏置较高。
- 随着模型复杂度增加，模型能够表示更丰富的函数，偏置通常逐渐降低。
- 例如，用一条直线拟合明显弯曲的数据时会产生较高偏置；使用适当次数的多项式后，偏置会降低。

5.2 方差与复杂度

方差表示训练数据发生变化时，模型预测结果变化的程度。

- 简单模型受单个训练样本影响较小，方差通常较低。
- 复杂模型能够追随训练数据中的细节和噪声，对训练集变化更加敏感，因此方差通常较高。
- 例如，高次多项式或深度很大的决策树可能因少量样本变化而得到明显不同的预测结果。

因此，模型复杂度增加时通常表现为：

bias 下降, variance 上升.

5.3 训练集误差

随着模型复杂度增加，模型拥有更强的拟合能力，训练集上的预测误差一般会持续下降或至少不会上升。

- 在低复杂度区域，训练误差较高，说明模型连训练数据中的主要规律也没有充分学到。
- 在高复杂度区域，训练误差可能非常低，甚至接近 0，但这并不一定表示模型对新数据也有良好表现。

图中的训练误差曲线因此呈现随模型复杂度增加而不断下降的趋势。

5.4 测试集误差

测试集误差通常呈 U 形变化：

1. 模型过于简单时，高偏置占主导，测试误差较高。
2. 复杂度适当时，模型既能学到主要规律，又没有过度追随噪声，测试误差达到最低。
3. 模型过于复杂时，高方差占主导，测试误差重新升高。

对平方损失，测试点上的期望预测误差可以分解为

$$\left[\left(y - \hat{y}(x) \right)^2 \right] = \sigma^2 + bias^2[\hat{y}(x)] + a[\hat{y}(x)],$$

其中：

- (σ^2) 是数据本身不可约的噪声；
- $(bias^2)$ 是偏置平方；
- (a) 是方差。

增加模型复杂度会降低偏置，却会提高方差。测试误差的最低点体现了偏置与方差之间较好的平衡。

5.5 三种拟合现象

模型复杂度	偏置	方差	训练误差	测试误差	拟合现象
过低	高	低	较高	较高	欠拟合
适中	适中	适中	较低	最低	泛化较好
过高	低	高	很低	重新升高	过拟合

选择模型时不能只比较训练误差，而应利用验证集或交叉验证选择使泛化误差较低的模型复杂度。

第四讲作业

1. 解决分类问题的三种方法

解决分类问题通常可以从判别函数、生成式概率模型和判别式概率模型三种思路出发。

1.1 直接构造判别函数

这种方法直接学习一个判别函数

$$f(\mathbf{x}),$$

再根据函数值决定样本类别。例如在二分类中，可以使用

$$\hat{y} = \begin{cases} 1, & f(\mathbf{x}) > 0, \\ 0, & f(\mathbf{x}) \leq 0. \end{cases}$$

它不一定显式计算类别概率，重点是直接找到能够区分不同类别的决策边界。

算法实例：支持向量机 SVM。 SVM 通过最大化两类样本与分隔超平面之间的间隔来构造分类边界。

1.2 生成式概率模型

生成式方法分别估计类别先验概率和类条件分布：

$$p(C), \quad p(\mathbf{x}|C).$$

再利用贝叶斯公式计算后验概率：

$$p(C|\mathbf{x}) = \frac{p(\mathbf{x}|C)p(C)}{p(\mathbf{x})}.$$

最后选择后验概率最大的类别。因为该方法对数据在各类别中的生成过程进行建模，所以称为生成式方法。

算法实例：朴素贝叶斯。 它在给定类别的条件下假设各特征相互独立，从而简化类条件概率的计算。

1.3 判别式概率模型

判别式概率模型直接建立后验概率

$$p(C|\mathbf{x})$$

与输入特征之间的关系，而不显式估计 $p(\mathbf{x}|C)$ 。该方法既可以给出类别，也可以给出属于各类别的概率。

算法实例：Logistic 回归。 二分类 Logistic 回归直接建立 $P(y=1|\mathbf{x})$ 与特征的关系。

2. Logistic 回归分类模型的三要素

统计学习方法通常由模型、策略和算法三个要素组成。对 Logistic 回归，这三个要素如下。

2.1 模型

二分类 Logistic 回归模型为

$$(y = 1|\boldsymbol{x}) = \sigma(\boldsymbol{w}^T \boldsymbol{x} + b) = \frac{1}{1 + \exp[-(\boldsymbol{w}^T \boldsymbol{x} + b)]},$$
$$(y = 0|\boldsymbol{x}) = 1 - (y = 1|\boldsymbol{x}).$$

它也可以写成对数几率的线性形式：

$$\log \frac{(y = 1|\boldsymbol{x})}{(y = 0|\boldsymbol{x})} = \boldsymbol{w}^T \boldsymbol{x} + b.$$

2.2 策略

Logistic 回归通常采用极大似然估计学习参数，等价于最小化二元交叉熵损失：

$$J(\boldsymbol{w}, b) = - \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)],$$

其中

$$p_i = (y_i = 1|\boldsymbol{x}_i).$$

为了控制模型复杂度，还可以在损失函数中加入 (1) 或 (2) 正则化项。

2.3 算法

由于 Logistic 回归一般没有与普通最小二乘相同形式的直接闭式解，需要使用数值优化算法求解参数。常见算法包括：

- 梯度下降法；
- 随机梯度下降法；
- 牛顿法；
- 拟牛顿法；
- 迭代重加权最小二乘法。

训练完成后，通常以 (0.5) 为阈值：

$$\hat{y} = \begin{cases} 1, & (y = 1|\boldsymbol{x}) \geq 0.5, \\ 0, & (y = 1|\boldsymbol{x}) < 0.5. \end{cases}$$

3. 线性回归与 Logistic 回归对比

比较维度	线性回归	Logistic 回归			
目标变量	连续数值变量	离散类别变量，基本形式为二分类 (y 0, 1)			

比较维度	线性回归	Logistic 回归			
观测分布	通常假设 $(y x)$ 服从高斯分布	二分类时假设 $(y x)$ 服从伯努利分布，多次计数时可用二项分布			
线性预测子	$= \boldsymbol{w}^T \boldsymbol{x} + b$	$= \boldsymbol{w}^T \boldsymbol{x} + b = \log \frac{p}{1-p}$			
输出	直接输出目标变量的预测值或条件均值 $\hat{y} =$	先输出类别概率 $p = \sigma()$ ，再根据阈值输出类别			
训练目标损失函数	最小化平方误差，等价于高斯噪声假设下的极大似然估计	最小化交叉熵或对数损失，等价于伯努利分布假设下的极大似然估计			
输出范围	$(-, +)$	概率输出范围为 $(0,1)$ ，最终类别通常为 0 或 1			
决策边界	本身用于回归，没有固有的分类决策边界；若人为设置阈值，则可得到相应边界	当阈值为 0.5 时，边界满足 $\boldsymbol{w}^T \boldsymbol{x} + b = 0$ ，在原始特征空间中是线性超平面			

两种方法都使用线性预测子，但用途和概率假设不同。线性回归直接拟合连续数值；Logistic 回归用 Sigmoid 函数把线性预测子映射为概率，因此更适合分类问题。

4. 使用朴素贝叶斯估计客户性别

题目给出的 8 个样本如下：

编号	身高	体重	鞋码	性别
1	高	重	大	男
2	高	重	大	男
3	中	中	大	男
4	中	中	中	男
5	矮	轻	小	女
6	矮	轻	小	女
7	矮	中	中	女
8	中	中	中	女

现在需要判断的新客户特征为

$X = (\text{身高中}, \text{体重中}, \text{鞋码中}).$

朴素贝叶斯假设：在给定性别的条件下，身高、体重和鞋码三个特征相互独立。因此

$$(C|X)(C)(\text{身高中}|C)(\text{体重中}|C)(\text{鞋码中}|C),$$

其中 (C) 表示性别类别。

4.1 男性的未归一化后验概率

样本中有 4 名男性、4 名女性，所以

$$(\text{男}) = \frac{4}{8} = \frac{1}{2}.$$

在 4 名男性中：

- 身高为“中”的有 2 人；
- 体重为“中”的有 2 人；
- 鞋码为“中”的有 1 人。

因此

$$(\text{身高中}|\text{男}) = \frac{2}{4} = \frac{1}{2},$$

$$(\text{体重中}|\text{男}) = \frac{2}{4} = \frac{1}{2},$$

$$(\text{鞋码中}|\text{男}) = \frac{1}{4}.$$

男性的未归一化后验概率为

$$\begin{aligned}(\text{男})(X|\text{男}) &= \frac{1}{2} \frac{1}{2} \frac{1}{2} \frac{1}{4} \\ &= \frac{1}{32}.\end{aligned}$$

4.2 女性的未归一化后验概率

女性先验概率为

$$(\text{女}) = \frac{4}{8} = \frac{1}{2}.$$

在 4 名女性中：

- 身高为“中”的有 1 人；
- 体重为“中”的有 2 人；
- 鞋码为“中”的有 2 人。

因此

$$(\text{身高中}|\text{女}) = \frac{1}{4},$$

$$(\text{体重中}|\text{女}) = \frac{2}{4} = \frac{1}{2},$$

$$(\text{鞋码中}|\text{女}) = \frac{2}{4} = \frac{1}{2}.$$

女性的未归一化后验概率为

$$\begin{aligned} (\text{女})(X|\text{女}) &= \frac{1}{2} \frac{1}{4} \frac{1}{2} \frac{1}{2} \\ &= \frac{1}{32}. \end{aligned}$$

4.3 归一化与结论

因为两个类别的未归一化后验概率相同，所以

$$(\text{男}|X) = \frac{\frac{1}{32}}{\frac{1}{32} + \frac{1}{32}} = \frac{1}{2},$$

$$(\text{女}|X) = \frac{\frac{1}{32}}{\frac{1}{32} + \frac{1}{32}} = \frac{1}{2}.$$

最终结果为

$$\boxed{(\text{男}|X) = (\text{女}|X) = 0.5}.$$

因此，根据当前 8 个样本和朴素贝叶斯的条件独立假设，该客户被判断为男性和女性的概率相同，无法仅凭现有数据唯一确定性别。如果分类系统必须输出一个类别，则还需要规定平局处理规则，或加入更多训练样本和其他有效特征。

即使对每个离散特征采用加一平滑，两类的计算结果仍然相同，因此不会改变本题的平局结论。