

姓名：徐诗霖

学号：202622080929

1 硬间隔支持向量机

训练样本为：

- 正类 $+1$: $(2, 2), (4, 4), (4, 0)$
- 负类 -1 : $(0, 0), (2, 0), (0, 2)$

1(a) 最优分类面、权向量和间隔

负类凸包靠近正类的一条边是

$$x_1 + x_2 = 2,$$

正类凸包靠近负类的一条边是

$$x_1 + x_2 = 4.$$

两条边平行，因此最大间隔分类面位于二者正中间：


$$x_1 + x_2 - 3 = 0.$$

写成 $w_1x_1 + w_2x_2 + b = 0$ ，可取

$$w = (1, 1)^T, \quad b = -3.$$

权向量 w 垂直于分类面，并指向函数值增大的正类一侧。(图表见下页)

Hard-margin SVM for the six training samples



分类面到任一最近样本点的距离为

$$\text{margin} = \frac{|x_1 + x_2 - 3|}{\sqrt{1^2 + 1^2}} = \boxed{\frac{1}{\sqrt{2}}}.$$

题目将 margin 定义为“分类面到最近点的距离”，所以答案是

$$1/\sqrt{2}$$

。若把两侧支持超平面之间的总宽度称为间隔，则总宽度为

$$\frac{2}{\|w\|} = \sqrt{2}.$$

1(b) 支持向量

在规范化参数

$$w = (1, 1)^T, b = -3$$

下，支持向量满足

$$y_i(w^T x_i + b) = 1.$$

逐点计算可得：

- 正类 (2, 2):

$$w^T x + b = 1$$

- 正类 (4, 0):

$$w^T x + b = 1$$

- 负类 (2, 0): $w^T x + b = -1$, 乘以 $y = -1$ 后为 1
- 负类 (0, 2): 同理为 1

因此支持向量为

$$\boxed{(2, 2), (4, 0), (2, 0), (0, 2)}.$$

它们恰好落在两条支持超平面 $x_1 + x_2 = 4$ 和 $x_1 + x_2 = 2$ 上，是离决策面最近的训练点；移动这些点可能改变最优分类面。其余两点的函数间隔严格大于 1，不是支持向量。

2 核技巧为什么不会因高维特征空间而显著增加运行时间

SVM 的对偶问题为

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j,$$

约束为

$$\alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0.$$

把输入映射到高维空间 $\phi(x)$ 后，算法只需要使用特征向量的内积

$$\phi(x_i)^T \phi(x_j).$$

核函数直接计算这个内积：

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j),$$

因此不必显式构造可能非常高维甚至无限维的 $\phi(x)$ 。预测函数也可写为

$$f(x) = \sum_{i \in SV} \alpha_i y_i K(x_i, x) + b,$$

只需要对支持向量计算核函数。这就是核技巧能够在高维特征空间训练非线性 SVM，而计算量通常不会随显式特征维数急剧增长的原因。

需要注意，“不显著增加”并不表示核 SVM 对大样本总是便宜：训练通常需要构造或访问 $n \times n$ 核矩阵，时间和内存开销会随样本数 n 增大；预测开销也与支持向量数量有关。

3 凸优化中的等式约束与不等式约束优化

3.1 等式约束优化

考虑

$$\min_x f(x), \quad \text{s.t. } h_i(x) = 0, \quad i = 1, \dots, m.$$

构造拉格朗日函数

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i h_i(x).$$

一阶必要条件是

$$\nabla_x L(x, \lambda) = 0, \quad h_i(x) = 0.$$

求解这些方程可以得到候选最优点。若问题为凸问题、目标函数凸且等式约束为仿射函数，则满足上述条件的可行点是全局最优解。数值计算中常用消元法、拉格朗日乘子法、等式约束牛顿法等。

3.2 不等式约束优化

考虑

$$\min_x f(x), \quad \text{s.t. } g_i(x) \leq 0, \quad h_j(x) = 0.$$

拉格朗日函数为

$$L(x, \lambda, \nu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \nu_j h_j(x),$$

其中不等式约束乘子必须满足

$$\lambda_i \geq 0$$

。最优点通常由 KKT 条件刻画：

1. 原始可行性： $g_i(x^*) \leq 0, \quad h_j(x^*) = 0$ ；
2. 对偶可行性： $\lambda_i^* \geq 0$ ；
3. 驻点条件： $\nabla_x L(x^*, \lambda^*, \nu^*) = 0$ ；
4. 互补松弛： $\lambda_i^* g_i(x^*) = 0$ 。

互补松弛说明：若某约束在最优点不活跃，即 $g_i(x^*) < 0$ ，则对应乘子为 0；若乘子大于 0，则该约束必定取等号。在凸问题并满足适当约束资格条件（如 Slater 条件）时，KKT 条件也是充分条件。常用算法包括活跃集法、障碍函数法和原始—对偶内点法。

4 支持向量机的风险、损失函数及与逻辑回归的比较

4.1 SVM 目标函数

令 $f(x) = w^T x + b$ 。软间隔 SVM 可写为

$$\min_{w,b} \underbrace{\frac{1}{2} \|w\|_2^2}_{\text{结构风险}} + C \underbrace{\sum_{i=1}^n \max(0, 1 - y_i f(x_i))}_{\text{经验风险}}.$$

- **结构风险** $\frac{1}{2} \|w\|^2$ ：限制模型复杂度。减小

$$\|w\|$$

等价于增大几何间隔，有利于提高泛化能力。

- **经验风险**：惩罚训练样本的间隔违例和误分类，使模型拟合训练数据。
- **参数 C** ：调节二者的权衡。 C 越大，越重视训练误差； C 越小，越强调大间隔和正则化。

也可用平均损失形式写成 $\frac{\lambda}{2} \|w\|^2 + \frac{1}{n} \sum_i \ell_i$ ，两种写法本质相同，只是参数尺度不同。

4.2 铰链损失与对数损失


令分类间隔 $z = yf(x)$ 。

铰链损失为

$$\ell_{\text{hinge}}(z) = \max(0, 1 - z).$$

逻辑回归的对数损失为

$$\ell_{\log}(z) = \log(1 + e^{-z}).$$



两者都随分类间隔 z 增大而减小，但铰链损失在

$$z \geq 1$$

后等于 0；对数损失则平滑下降，只在 $z \rightarrow +\infty$ 时趋近 0。

4.3 远离决策面的正确分类样本为何影响不同

若一个样本被正确分类且满足 $z = yf(x) > 1$ ，则

$$\ell_{\text{hinge}}(z) = 0, \quad \frac{\partial \ell_{\text{hinge}}}{\partial z} = 0.$$

因此它不是支持向量，对 SVM 目标函数关于决策面参数的梯度贡献为 0，不会改变最优决策面。

对逻辑回归，

$$\frac{\partial \ell_{\log}}{\partial z} = -\frac{1}{1 + e^z}.$$

对于任何有限的 z ，该导数都不严格等于 0。因此远离决策面的正确分类点仍有一个很小但非零的梯度贡献，原则上仍会影响逻辑回归的参数和决策面；只是当 z 很大时，这种影响会非常小。

5 EM 算法与混合高斯模型

5.1 EM 算法的一般流程

设观测变量为 X ，隐变量为 Z ，参数为 θ 。EM 算法反复执行：

1. 初始化参数 $\theta^{(0)}$ ；
2. **E 步**：在当前参数下计算隐变量的后验分布，并构造完整数据对数似然的条件期望

$$Q(\theta, \theta^{(t)}) = \mathbb{E}_{Z|X, \theta^{(t)}} [\log p(X, Z | \theta)];$$

3. **M 步**：最大化该期望

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta, \theta^{(t)});$$

4. 若对数似然增量或参数变化小于阈值则停止，否则返回 E 步。

EM 每轮不会降低观测数据对数似然，但一般只能保证收敛到局部最优点或鞍点，因此初始化很重要。

5.2 GMM 的完整数据对数似然

对含 K 个分量的 GMM，设

$$p(x_n | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k), \quad \sum_{k=1}^K \pi_k = 1.$$

引入 one-hot 隐变量 $z_{nk} \in \{0, 1\}$ ，且 $\sum_k z_{nk} = 1$ 。完整数据联合概率为

$$p(X, Z | \theta) = \prod_{n=1}^N \prod_{k=1}^K [\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)]^{z_{nk}}.$$

因此完整数据对数似然为

$$\log p(X, Z | \theta) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} [\log \pi_k + \log \mathcal{N}(x_n | \mu_k, \Sigma_k)].$$

把高斯密度展开后，

$$\log \mathcal{N}(x_n | \mu_k, \Sigma_k) = -\frac{d}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x_n - \mu_k)^T \Sigma_k^{-1} (x_n - \mu_k).$$

5.3 E 步

计算样本 x_n 属于第 k 个分量的后验概率，也称责任度：

$$\gamma_{nk} = p(z_{nk} = 1 | x_n, \theta^{(t)}) = \frac{\pi_k^{(t)} \mathcal{N}(x_n | \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \mathcal{N}(x_n | \mu_j^{(t)}, \Sigma_j^{(t)})}.$$

5.4 M 步

令有效样本数

$$N_k = \sum_{n=1}^N \gamma_{nk}.$$

参数更新为

$$\pi_k^{(t+1)} = \frac{N_k}{N},$$

$$\mu_k^{(t+1)} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} x_n,$$

$$\Sigma_k^{(t+1)} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (x_n - \mu_k^{(t+1)})(x_n - \mu_k^{(t+1)})^T.$$

6 GMM 聚类、K-means 聚类及二者关系

6.1 GMM 中的 K 个高斯分量

每个高斯分量代表数据中的一个潜在子群或生成机制，由以下参数描述：

- π_k ：该类在总体中的先验比例；
- μ_k ：该类的中心；
- Σ_k ：该类的形状、尺度以及不同特征之间的相关性。

聚类时通常把样本分到后验责任度最大的分量：

$$\hat{c}_n = \arg \max_k \gamma_{nk}.$$

GMM 的 E 步与 M 步分别是：

- **E 步**：固定 π_k, μ_k, Σ_k ，用贝叶斯公式计算每个样本属于各分量的软概率 γ_{nk} ；
- **M 步**：固定责任度，用责任度作为权重，重新估计各分量的 π_k, μ_k, Σ_k 。公式与第 5 题相同。

6.2 K-means 的对应两步

K-means 最小化簇内平方和

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|x_n - \mu_k\|^2,$$

其中 $r_{nk} \in \{0, 1\}$ 且 $\sum_k r_{nk} = 1$ 。

E 步（分配步）：固定簇中心，将样本硬分配给最近的中心：

$$r_{nk} = \begin{cases} 1, & k = \arg \min_j \|x_n - \mu_j\|^2, \\ 0, & \text{其他.} \end{cases}$$

M 步（更新步）：固定分配，计算每一簇的均值：

$$\mu_k = \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}}.$$

6.3 区别与联系

比较项	GMM	K-means
分配方式	软分配, $\gamma_{nk} \in [0, 1]$	硬分配, $r_{nk} \in \{0, 1\}$
优化目标	最大化概率模型的对数似然	最小化簇内平方距离和
簇的描述	比例、均值、协方差	主要是簇中心
簇的形状	可表示不同大小、方向和椭圆形状	更适合大小相近的球形簇
不确定性	能给出属于各簇的概率	只给出单一簇标签

两者都采用“分配样本、更新参数”的交替迭代结构，且都可能收敛到局部最优，因此通常需要多次随机初始化。在各高斯分量具有相同的球形协方差 $\Sigma_k = \sigma^2 I$ 、先验相同，并令 $\sigma^2 \rightarrow 0$ 时，GMM 的软责任度趋于 0/1 硬分配，EM 更新就趋近于 K-means。因此 K-means 可看作特定条件下 GMM-EM 的极限形式。

7 神经网络前向传播与梯度

输入为

$$x = (x_1, x_2) = (0.5, 1),$$

隐藏层使用 Sigmoid，输出层为线性函数。按题图和开头说明，将权重写成

$$W_1 = \begin{bmatrix} 1 & -1 & 1 \\ 1 & 0.5 & 2 \end{bmatrix}, \quad W_2 = [1.5 \quad 2 \quad 1].$$

7(1) 网络输出

隐藏层线性输入为

$$a = xW_1 = [0.5 \quad 1] \begin{bmatrix} 1 & -1 & 1 \\ 1 & 0.5 & 2 \end{bmatrix} = [1.5 \quad 0 \quad 2.5].$$

隐藏层输出为

$$h = \sigma(a) = [\sigma(1.5) \quad \sigma(0) \quad \sigma(2.5)] \approx [0.817574 \quad 0.5 \quad 0.924142].$$

所以

$$\begin{aligned}\hat{y} &= hW_2^T \\ &= 1.5(0.817574) + 2(0.5) + 1(0.924142) \\ &\approx \boxed{3.150504}.\end{aligned}$$

7(2) 各参数的梯度

采用常见约定

$$L = \frac{1}{2}(\hat{y} - y)^2, \quad y = 4.$$

误差为

$$\delta_o = \frac{\partial L}{\partial \hat{y}} = \hat{y} - y = 3.150504 - 4 = -0.849496.$$

输出层权重的梯度为

$$\frac{\partial L}{\partial W_{2j}} = (\hat{y} - y)h_j,$$

故

$$\nabla_{W_2} L \approx \begin{bmatrix} -0.694527 & -0.424748 & -0.785055 \end{bmatrix}.$$

Sigmoid 导数为

$$\sigma'(a_j) = h_j(1 - h_j).$$

隐藏层第 j 个单元的误差信号为

$$\delta_j = \frac{\partial L}{\partial a_j} = (\hat{y} - y)W_{2j}h_j(1 - h_j).$$

数值为

$$\delta \approx \begin{bmatrix} -0.190049 & -0.424748 & -0.059553 \end{bmatrix}.$$

由于 $a_j = \sum_i x_i W_{1,ij}$, 有

$$\frac{\partial L}{\partial W_{1,ij}} = x_i \delta_j.$$

因此

$$\nabla_{W_1} L \approx \begin{bmatrix} -0.095025 & -0.212374 & -0.029776 \\ -0.190049 & -0.424748 & -0.059553 \end{bmatrix}.$$

若课程把“ L_2 损失”定义为不带 $1/2$ 的

$$L = (\hat{y} - y)^2,$$

则损失值为 0.721644，并且上述所有梯度整体乘以 2：

$$\nabla_{W_2} L \approx [-1.389053 \quad -0.849496 \quad -1.570110],$$

$$\nabla_{W_1} L \approx \begin{bmatrix} -0.190049 & -0.424748 & -0.059553 \\ -0.380098 & -0.849496 & -0.119106 \end{bmatrix}.$$